自动驾驶的数字蓝图：感知与规划的演进图谱

从单点技术突破到多模态融合的系统性重构

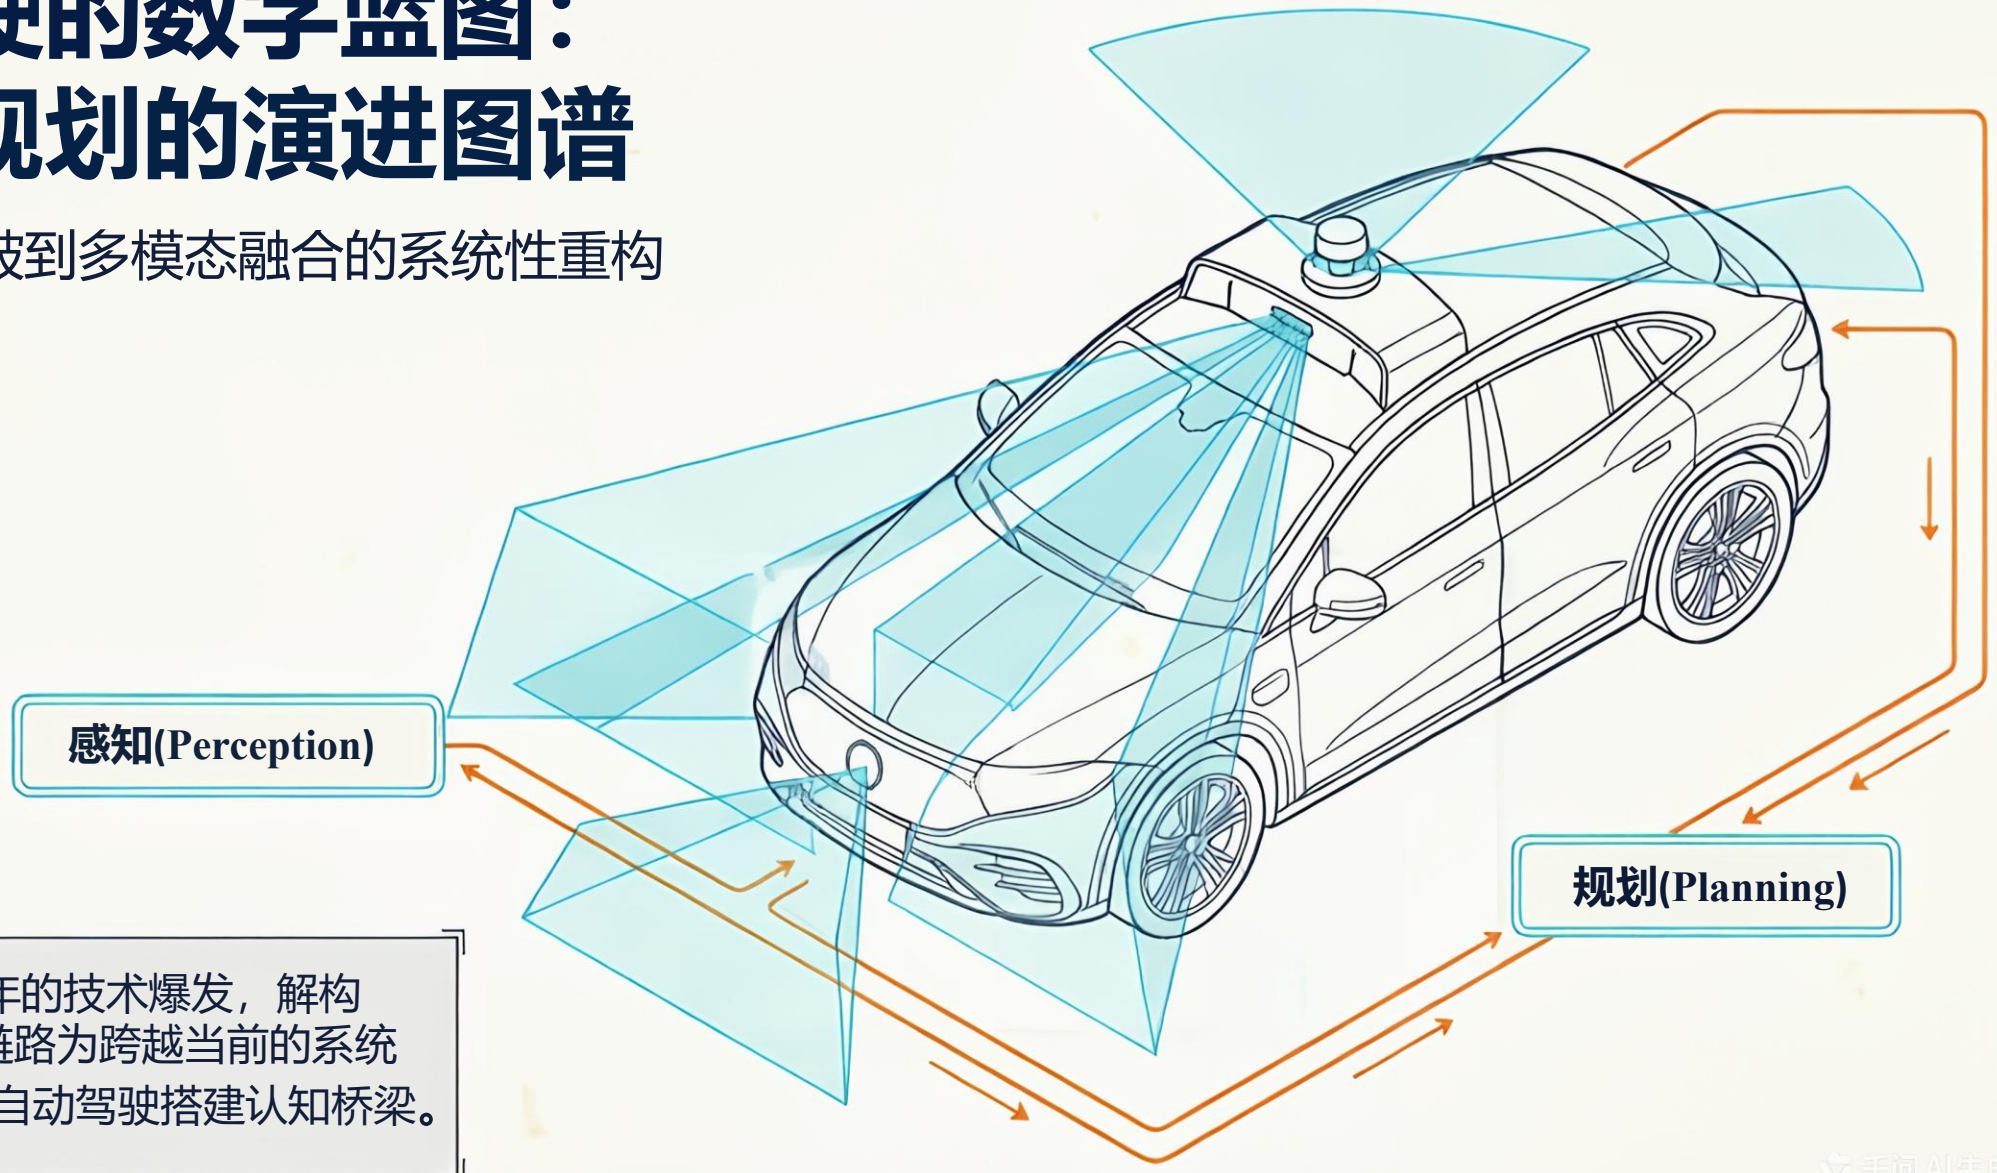

本PPT提炼过去十年的技术爆发，解构L0-L5系统的核心链路为跨越当前的系统瓶颈、迈向下一代自动驾驶搭建认知桥梁。

千问AI生成

全局架构：自动驾驶的系统解剖图

L0	L1	L2	L3	L4	L5
主动刹车	车道保持辅助	组合驾驶辅助	有条件自动驾驶	高度自动驾驶	完全自动驾驶

感知(Perception)

定位技术(Localization)
目标检测(Object Detection)
场景理解(Scene Understanding)
预测 (Prediction)
跟踪(Tracking)

规划(Planning)

全局路由规划
(Global Route Planning)
局部行为规划
(Local Behavior/Trajectory Planning)

控制（Control)

纵向控制 (Longitudinal Control)
横向控制 (Lateral Control)
高级控制策略 (Advanced Control Strategies)

Application Scenes

- Urban Roads
- Park Logistics
- Warehouses
- Ports
- Intelligent Mines
- Agriculture
- Wildlife Rescue
- Tunnel Search

感知系统全景拓扑图

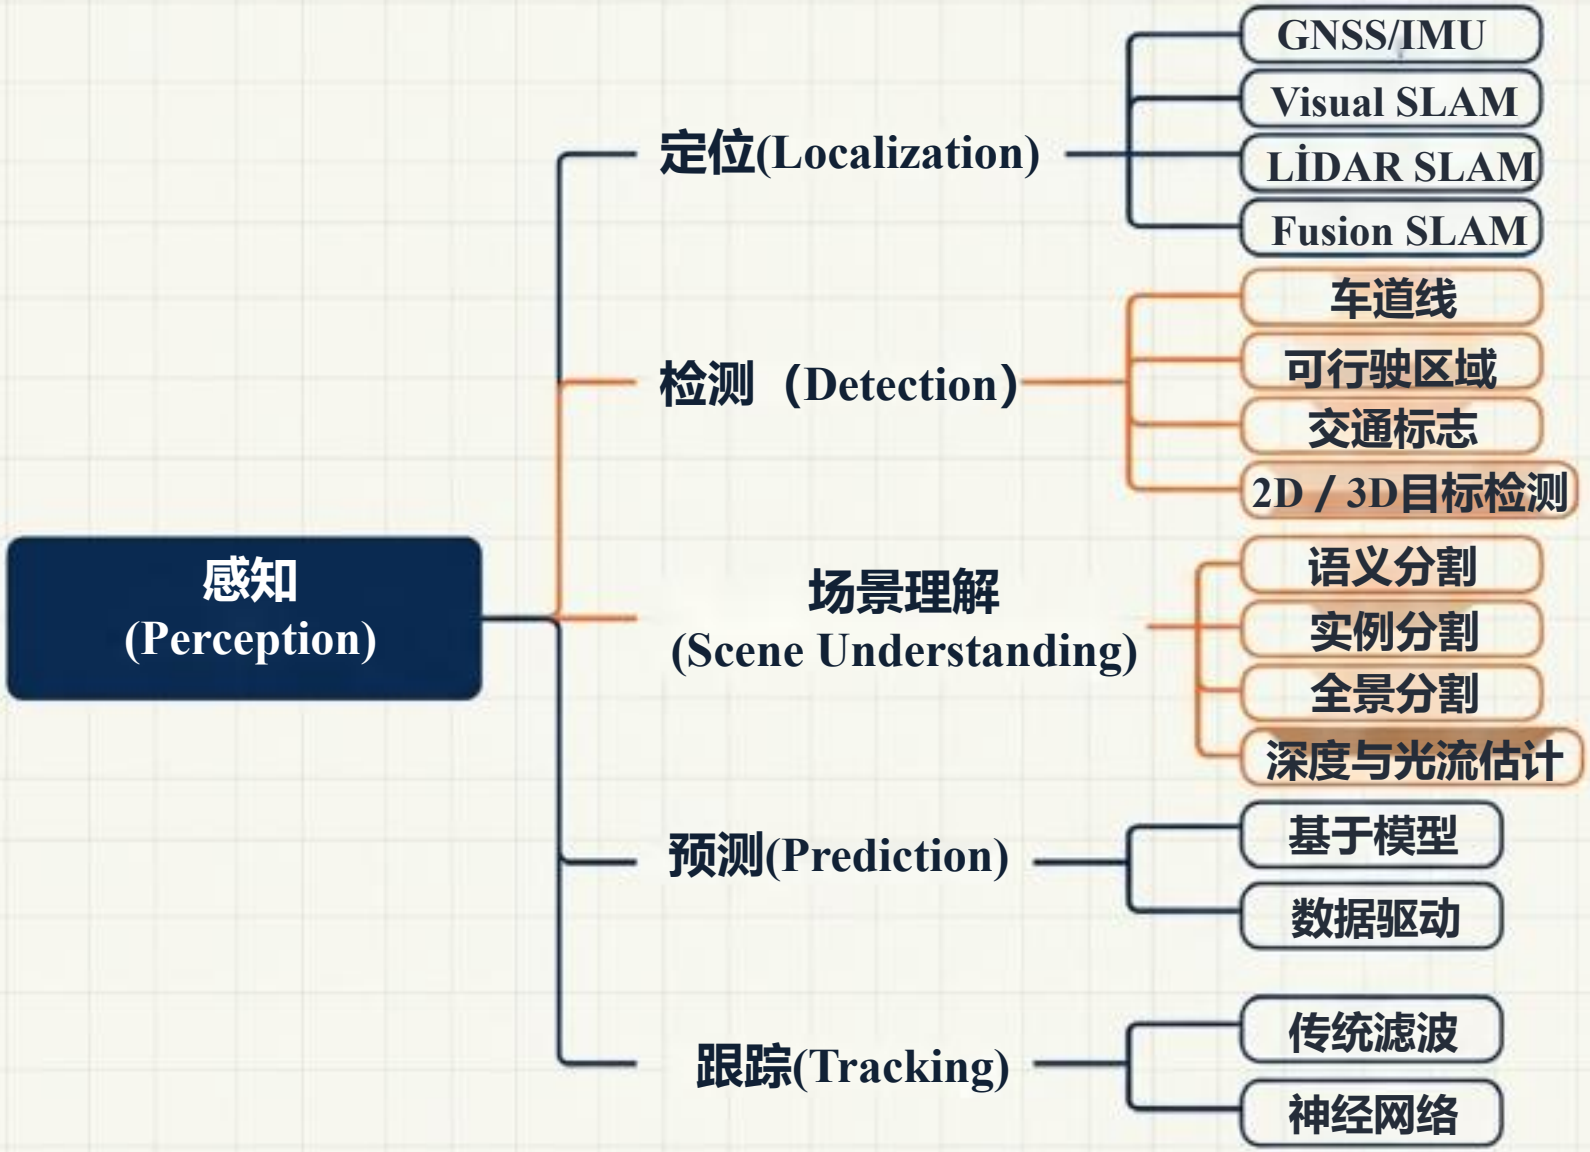

学生认为各种技术不完全是“逐步替代”的进化关系，更像是“层层叠加”的互补关系。

以定位技术为例如果把自动驾驶比作一个人：

1.GNSS 是方向感（知道自己在地球的哪个大概位置，但在隧道里会迷路）。

2.Visual (视觉) 是眼睛（能看到红绿灯、车道线、路牌，但晚上或大雾天会瞎）。

3.LiDAR 是触觉/手杖（能精准摸出障碍物距离，不受光线影响，但不知道那个东西是红还是绿，且很贵）。

4.Fusion (融合) 是大脑（把方向感、眼睛看到的、手摸到的信息综合起来，做出最准确的判断）。

所以，它们不是“有了 Fusion 就不需要 GNSS 了”，而是为了达到最高精度，必须把它们全部结合起来。

定位技术矩阵：寻找绝对坐标

GNSS/IMU	Visual SLAM (视觉)
【优势】全时域（All-day, All-weather），易配置，无外部传感器依赖。 【劣势】城市峡谷效应易导致信号丢失，高精度方案成本极高。	【优势】硬件成本低，可获取丰富的语义信息。 【劣势】极度依赖特征点，对光照和天气变化极其敏感（如 ORB - SLAM）。
LiDAR SLAM (激光雷达)	**Fusion-based (多源融合)**
【优势】精度极高，可构建高保真的稠密 3D 点云地图。 【劣势】缺乏色彩语义信息，易受雨雪等极端恶劣环境干扰。	【优势】消除单一传感器死角，鲁棒性最强。 【劣势】引入了极高的时间同步（Synchronization）与空间标定复杂性。

演进趋势：从松耦合（Loose Fusion）走向紧耦合（Tight Fusion）的联合优化

2D目标检测：从规则视觉到深度学习的进化

传统计算机视觉（CV-based）

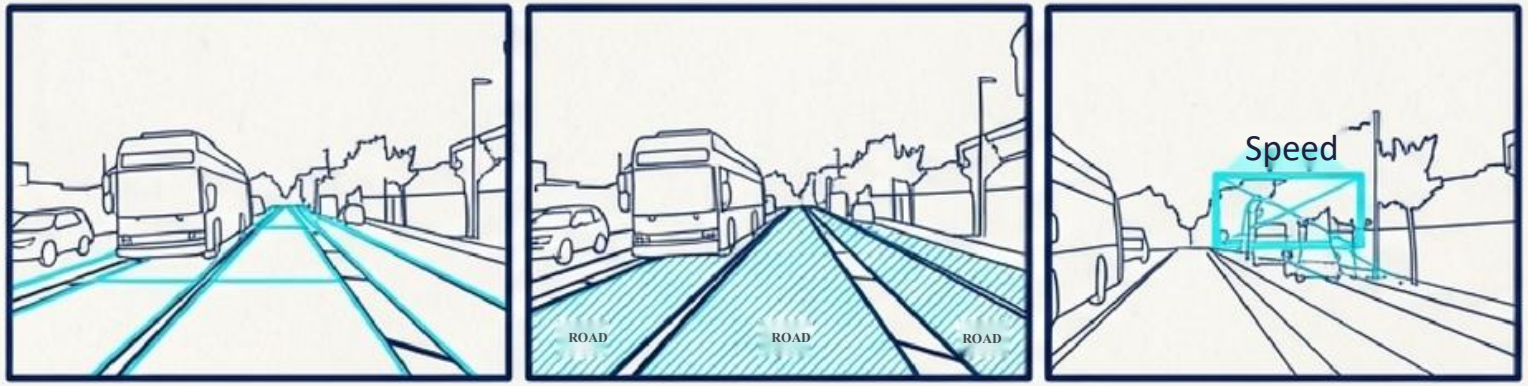

- 机制：依赖形态学、Hough 变换、色彩阈值与 SVM 分类器。
- 优势：算力消耗极低，易于在边缘设备部署。
- **劣势：面对光照骤变、目标遮挡、形态畸变时，系统极其脆弱。**

深度学习(Learning-based)

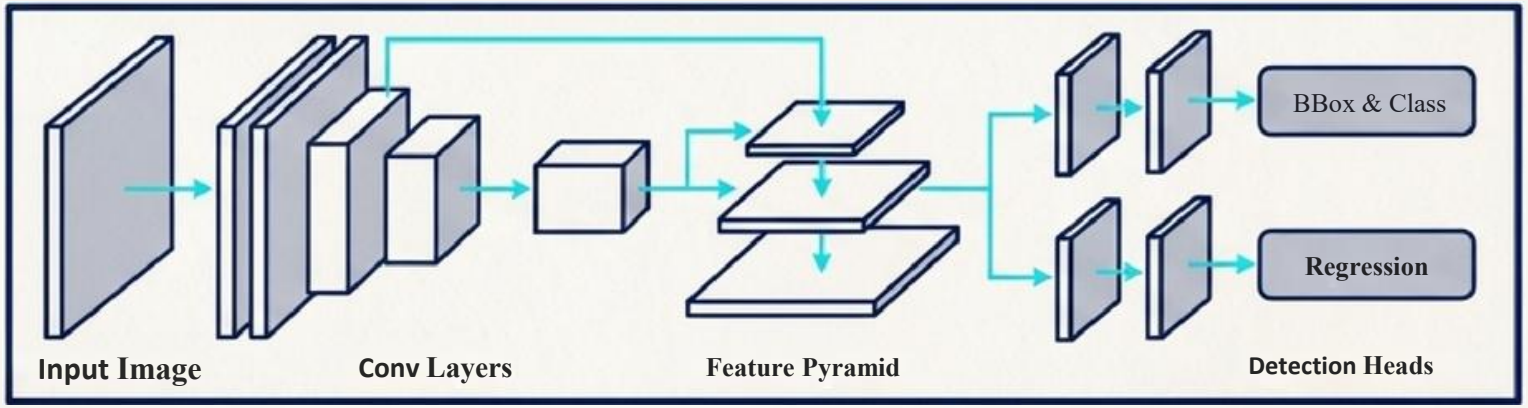

- 机制：依赖 CNN、多子头结构(Mul - ti-headers) 与级联 RCNN。
- 优势：隐式学习表征，对复杂畸变环境具有极高的宽容度与泛化力。
- **劣势：陷入数据饥渴，模型极度依赖海量高质量的人工标注。**

范式转移：特征提取的权力已从人类工程师（手工设计特征）全面让渡给多层神经网络（隐式学习表征）。

3D目标检测：三维空间的升维战争

视觉 3D (Visual-based)

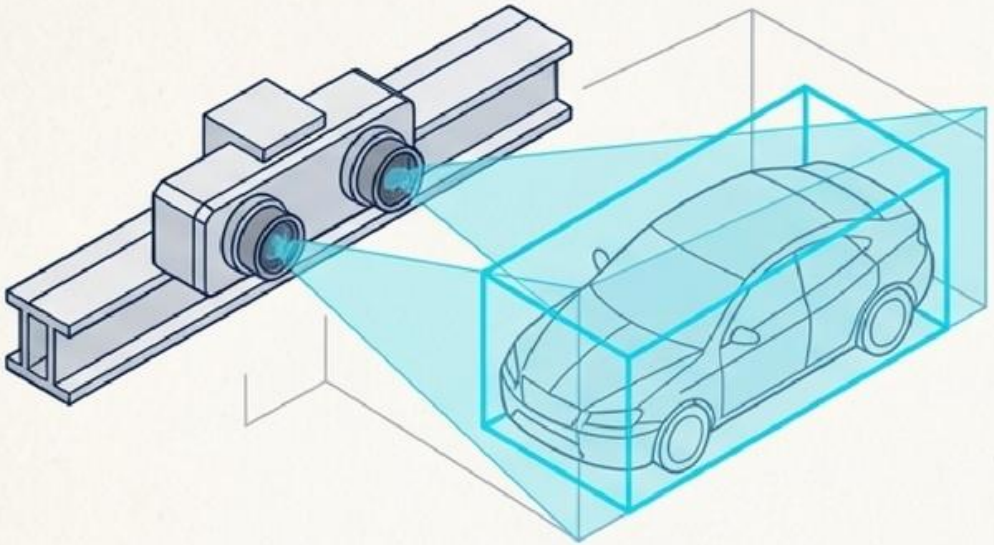

.单目(Monocular)

依赖几何约束和深度估计网络
痛点：从单张二维图像恢复三维属性本质上是“病态问题(III-posed problem) ”。

.双目（Stereo）

依赖视差分析。避免了病态问题，但引入了基线标定难题和极高的立体匹配算力负担。

激光雷达 3D (LiDAR-based)

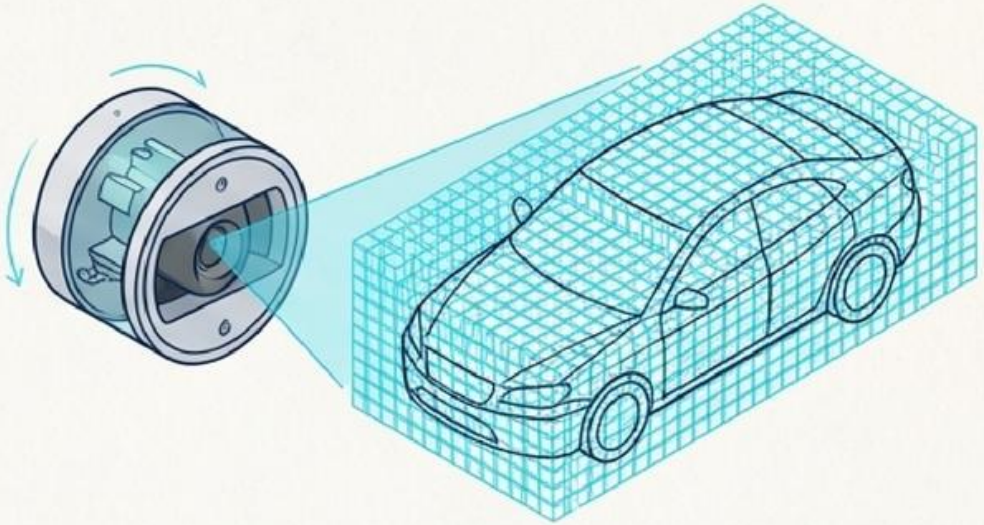

. 体素化(Voxel-wise)

将无序的点云划分为3D规则栅格，完美平衡了特征提取性能与计算效率（如 VoxelNet）。

.点云化(Point-wise)

直接基于原始稀疏点云提取特征空间，保留最高精度的几何形态（如 Point - RCNN）。

判定结论

在空间绝对精度上，点云检测目前占据绝对统治地位；但纯视觉方案凭借压倒性的成本优势和部署便利性，仍在依靠大模型持续发力。

多模态融合：1+1>2 的博弈与代价

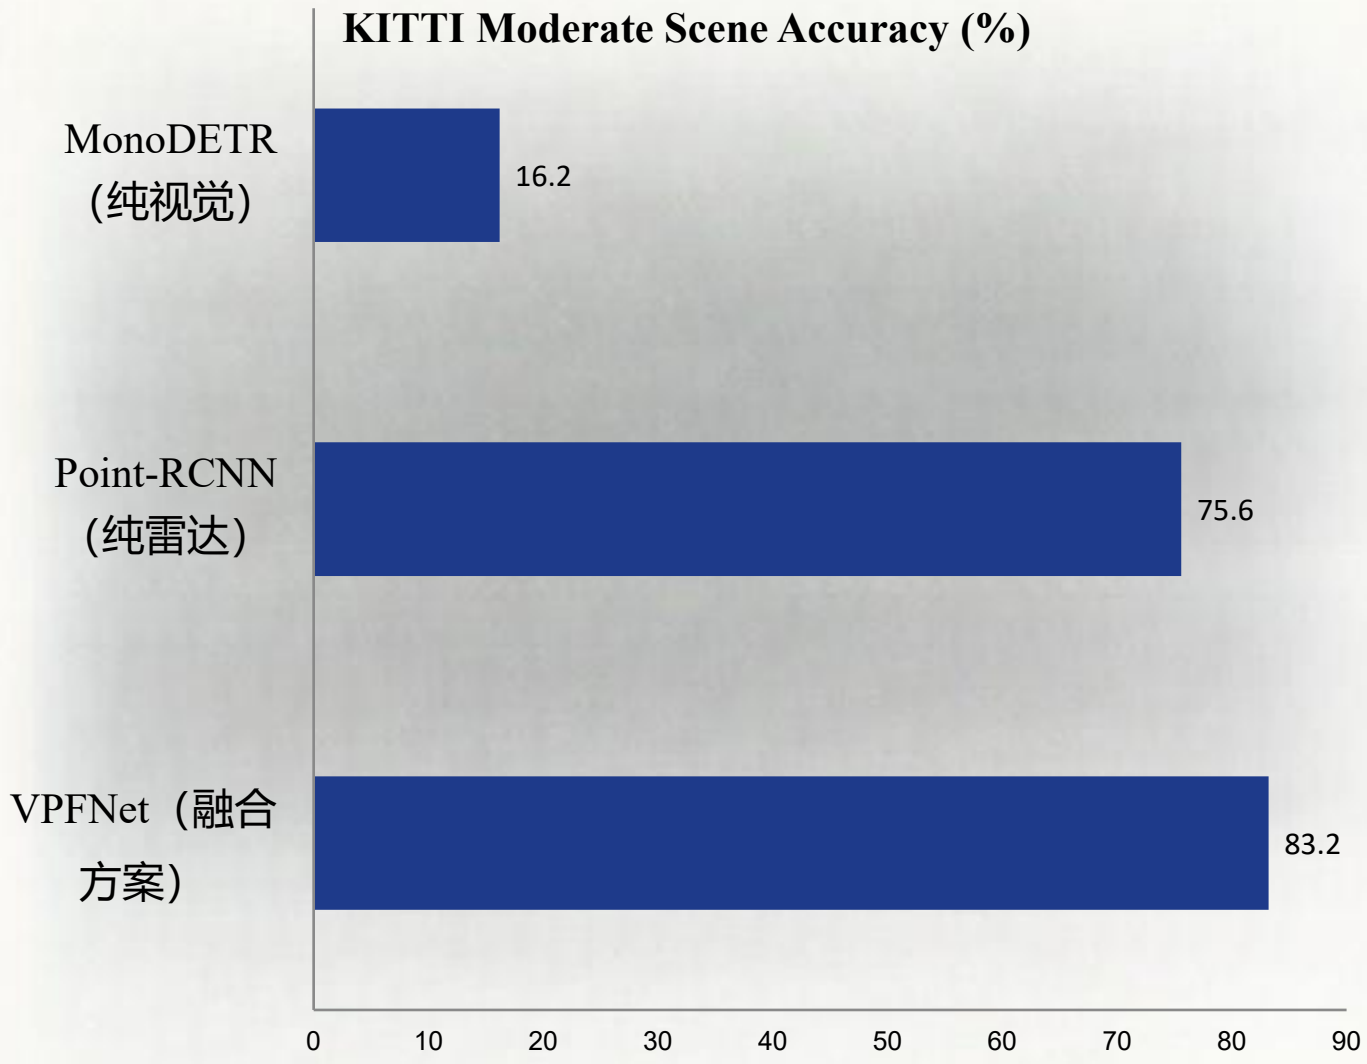

融合策略的取舍

并行融合（提取各自特征后拼接）导致计算冗余
序列融合（由 2D 引导 3D降低搜索区域）易受
前置模块误差干扰。

模态鸿沟(Modalities Gap)

图像的密集像素（2D语义）与 LiDAR 的稀疏点
云（3D几何）之间，存在天然的特征对齐壁垒。

系统误差放大器

多传感器之间的时间同步偏差与空间外参标定误
差，极易在深层神经网络中被非线性放大。

**技术趋势：引入自注意力机制（Transformer）
正在成为跨模态全局特征融合的银弹。**

场景理解：像素级的物理世界解码

Step 1: 语义分割(Semantic)

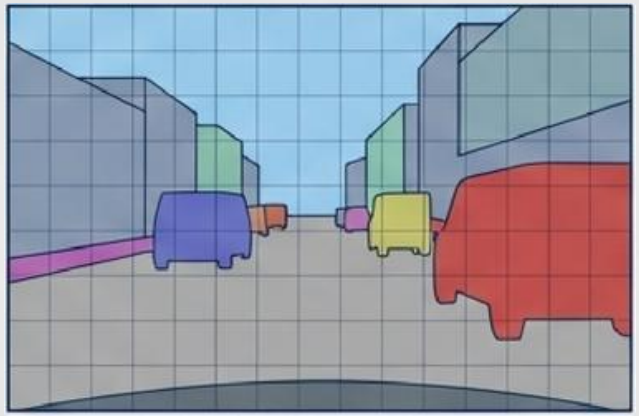

为视场内每一个独立像素贴上类别标签，但不区分同类别的不同个体

Step 2: 实例分割(Instance)

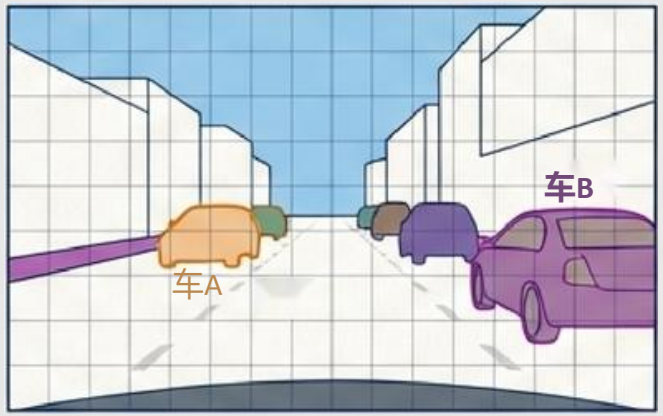

精准剥离并圈定出每一个独立的前景运动目标（如车A与车B）

Step 3: 全景分割(Panoptic)

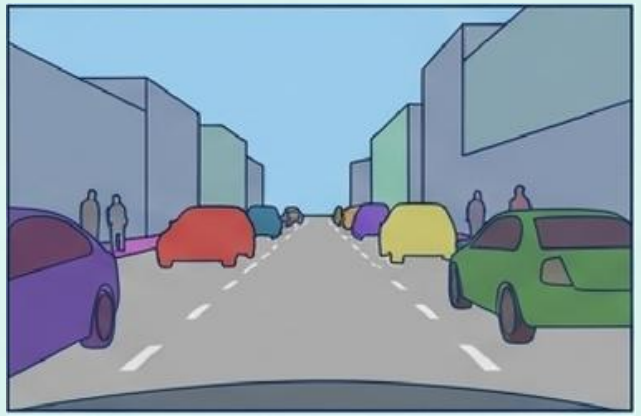

统一背景(Stuff) 与前景(Things)的终极解析形态，实现全要素的像素重构

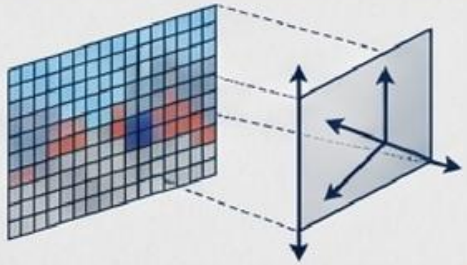

深度估计 （Depth）

将扁平的2D 像素阵列赋予空间景深，提供伪3D几何锚点。

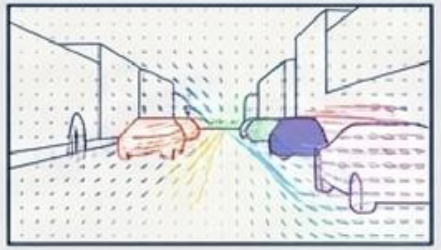

光流估计（Flow）

将2D 像素系赋予时间维度上的运动矢量，捕捉动态物体的瞬时物理轨迹

核心价值：场景理解不直接输出控制指令，而是为空间检测与跨域融合提供海量前置语义。

预测与跟踪：把握时间的脉搏

跟踪（Tracking-过去时间域）

预测(Prediction-未来概率域)

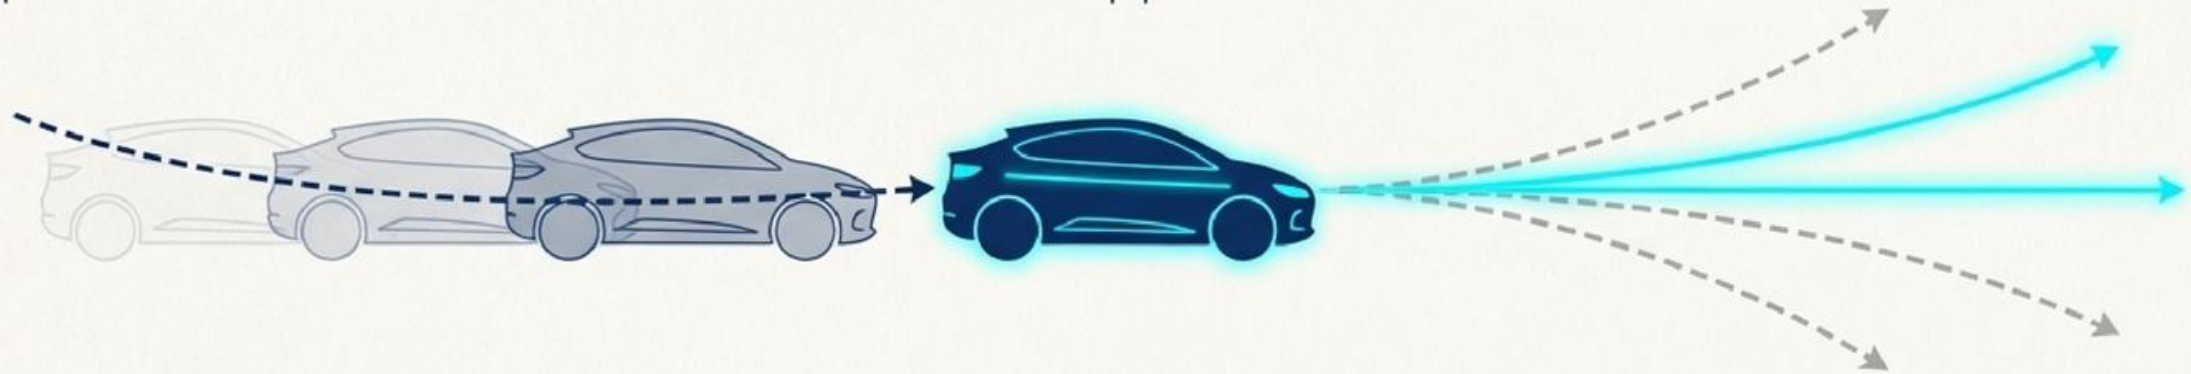

跟踪(Tracking)

- 传统方法：卡尔曼滤波(Kalman Filter)算力消耗极低，具有极速响应能力，是工业界的基石。
- 神经网络：基于 RNN / LSTM 的序列模型。完美解决目标被遮挡后再次出现时的身份重入(Re - enter)与数据关联难题。

预测(Prediction)

- 基于模型（Model - based）：依靠马尔可夫等状态机推演，规则清晰，但缺乏对复杂场景上下文的理解。
- 数据驱动（Data - driven）：采用编码器 - 解码器架构，不仅预测轨迹，更融合了交通参与者之间的交互博弈与意图推测

前沿共识：联合学习(Joint Learning)感知与跟踪正在告别串行流水线，走向在单一庞大网络中同时输出并互相纠错的融合架构。

规划引擎：连接感知与控制的大脑

全局路由规划(Global Route)

道路级别决策，基于带权有向拓扑图的 A * 或 Dijkstra 全局搜索功能类似于常规导航软件，输出从AB 的宏观路径节点

局部行为规划 (Local Behavior)

意图级别博弈，在接下来几秒的时间窗口内，根据周边动态障碍物，决定是执行跟车、变道、超车还是紧急避让

局部轨迹规划
(Local Trajectory)

将宏观行为转化为精确到厘米与毫秒的平滑几何曲，直接投遥给底盘线控系统执行

硬性法则：规划系统的最终输出必须是一组带有严密时间属性的轨迹

Trajectory而绝不 仅仅是静态空间的路径(Path)，否则车辆将**完全无法应对动态交互博弈。**

行为与轨迹博弈：应对动态复杂交互

场景一:跟车(Car-following)

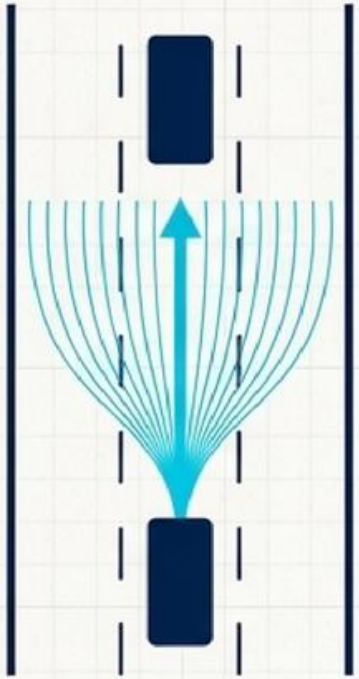

核心博弈：在动态交通流中，实现速度维度的平滑保持与安全距离的动态平衡。

场景二:换道/绕行 (Lane change/ Nudge)

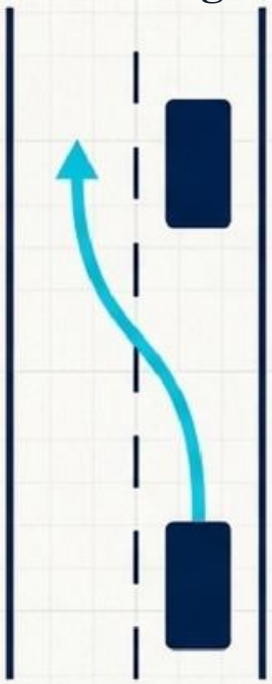

核心博弈：突破当前车道的物理几何约束，精准评估侧向切入的空间间隙与时间窗口。

场景三:避障 (Yield / Obstacle avoidance)

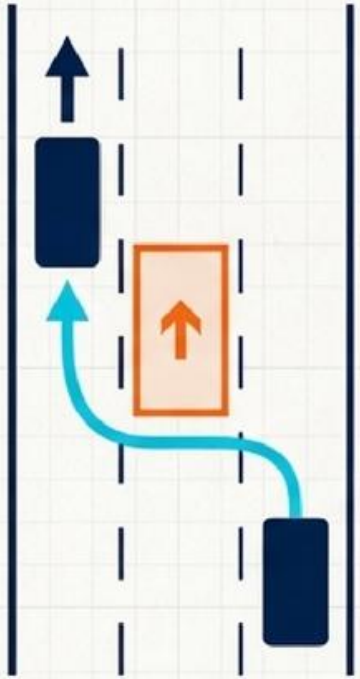

核心博弈：处理与静态障碍物以及高优路权对向来车之间的零和空间博弈。

工程设计原则：有限视距滚动优化(Receding-horizon)车辆永远只相信当前传感器视场内的真实测量数据，并以此高频重构接下来的局部最优解。

路线范式转移：序列规划 vs 端到端

序列规划(Sequential Planning)

- 架构基石：目前全球工业界量产落地的主流方案。
- 核心优势：系统边界极度清晰，逻辑严密。出现事故时具有极强的物理可解释性与代码级安全追溯性
- 核心痛点：模块之间存在严重的信息损耗与误差传递，为了应对长尾场景，代码规则复杂度呈指数级膨胀。

端到端规划 (End-to-End Planning)

- 架构基石：基于模仿学习(IL)与强化学习(RL)的前沿探索。
- 核心优势：彻底消除模块间的信息壁垒与人为制定的低效规则，系统理论性能上限极高。
- 核心痛点：黑盒机制导致可解释性(Interpretability)极差。在遭遇极端长尾场景(Corner cases)时，难以提供物理级别的安全兜底保障。

序列规划的底层手术室：最优控制求解

步骤一:状态网格识别 (State Grid Identification)

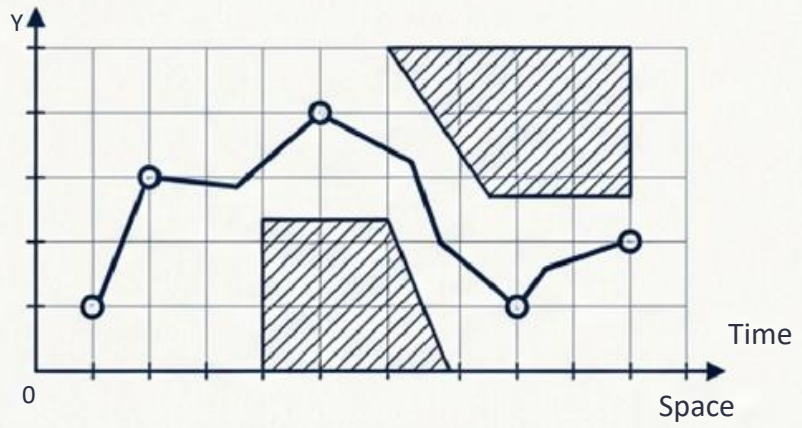

原理：在连续的时间-空间域中离散化出搜索≠拓扑图，寻找大体方向。
算法武器库： A*/DP 启发式搜索、马尔可夫决策(MDP)、数学规划（梯度优化）、人工势场法。

步骤二:基元生成(Primitive Generation)

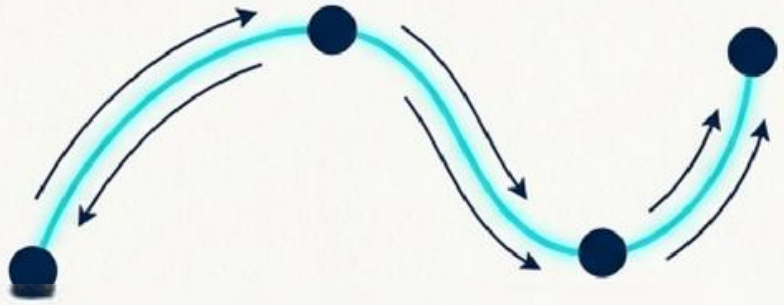

原理：将离散的网格点，用严格符合车辆动力学底盘约束的平滑曲线连接起来。
算法武器库: Dubins曲线、Reeds-Shepp曲线、高阶多项式插值优化。

→降维利器：路径 - 速度分解（PVD）

工业界标配做法: 将极其复杂的3D 时空轨迹求解,强行解耦降维成两个 2D子问题：XY 平面的空间路径规划 + ST 平面的时间速度规划。

数据与评测驱动的进化引擎

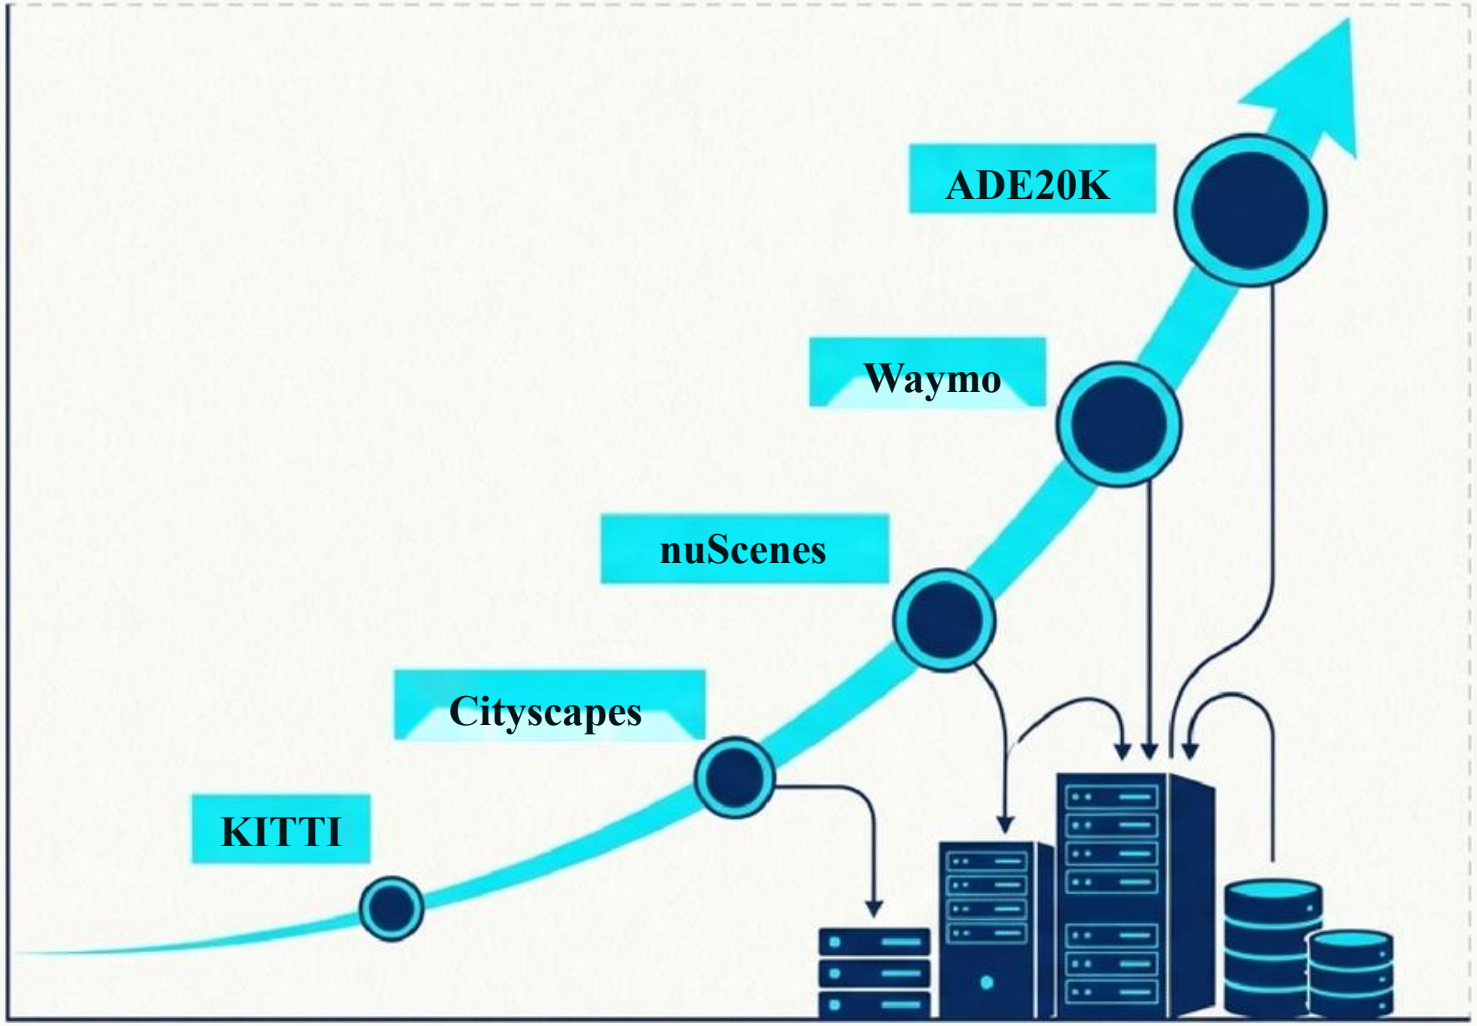

燃料迭代

早期算法高度依赖人类学家的数学推导，而明现代AI 的里程碑突破，极大程度上是由不断膨胀的 " 大规模、多模态 " 数据集直接喂养出来的。

评测标准倒逼

学术基准线从简单的 2D 边界框 (Bounding Box)，进化到 3D 空间精度评估，再到引入时间序列的动态预测评测，持续倒逼算法升维。

破局长尾效应

引入包含极端天气、无光照夜间、复杂遮挡的庞大对抗性样本库，是克服模型过拟合(Over-fit))并收敛 Corner cases 唯一的物理路径。

综合洞察：连接过去与未来的数字桥梁

当前的系统瓶颈（The Bottleneck）

经过长达十年的技术爆发，单一模块（纯感知或纯规划）的工程性能已逼近物理天花板。

•跨模态传感器的系统对齐误差仍难以彻底消除。

•极端恶劣天气下的鲁棒性断崖式劣化。

以上痛点是横亘在 L4/L5 级别全面量产落地面前的顽石。

未来的破局方向（The Future Bridge）

1. 架构大一统：寻找端到端黑盒与传统模块化架构的完美折中，发展具备物理可解释性的深度网络。

2. 泛化法则(Generalized Rules):摆脱对特定城市场景高精地图与硬编码规则的重度依赖，实现零样本泛化。

3. 协同闭环：彻底告别孤立的模块优化，迈向 ' 联合学习（Joint Learning） ' 与系统级自适应微调。

硬件算力设定了基础的下限， 而感知与规划算法的底层重塑，将最终决定自动驾驶真正落地的终局。